Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский университет ИТМО»

Математическая статистика
Расчётно-графическая работа №1

Описание выборки. Оценивание параметров.
Доверительные интервалы.

Выполнил: Старченко Александр
Преподаватель: Ланбин Юрий Владимирович

Вариант: реальные финансовые данные РФ
$n = 200$

Санкт-Петербург, 2026

Содержание

1 Данные и вариант **2**

2 Первичное описание выборки (п. 4.1) **2**
2.1 Эмпирические функции распределения 2
2.2 Гистограммы 3
2.3 Числовые характеристики 5
2.4 Описание формы 5

3 Предположение о виде закона распределения (п. 4.2) **5**

4 Оценивание параметров (п. 4.3) **5**
4.1 X_1: нормальное $N(a, \sigma)$ 5
4.2 X_2: экспоненциальное со сдвигом $Exp(\lambda, c)$ 5
4.3 X_3: равномерное $U(a, b)$ 6

5 Оценивание параметрической вероятности (п. 4.4) **6**

6 Моменты по сгруппированной выборке (п. 4.5) **7**

7 Доверительные интервалы (п. 4.6) **7**
7.1 Асимптотический ДИ для EX (по ЦПТ) 7
7.2 Точные ДИ для X_1 (нормальное распределение) 8
7.3 Интерпретация 8

8 Итоговый вывод (п. 4.7) **8**

9 Бонус: бимодальность и кластеризация X_4 **8**

1 Данные и вариант

Вместо синтетических данных использованы реальные финансовые данные РФ, загруженные с MOEX ISS API и сайта ЦБ РФ.

Таблица 1: Описание столбцов

Столбец	Данные	Источник	Распределение
X_1	Лог-доходности IMOEX	MOEX ISS API	$N(a, \sigma)$
X_2	Ставка рефинансирования ЦБ	cbr.ru/garant.ru	$Exp(\lambda, c)$
X_3	Копейки цены SBER	MOEX ISS API	$U(a, b)$
X_4	Цены IMOEX до/после 2022	MOEX ISS API	Бимодальное

X_1: 822 дневные цены закрытия IMOEX (2023–2026). Лог-доходность $r_t = \ln(P_t/P_{t-1})$. Последние 200 значений.

X_2: 140 записей ставки рефинансирования/ключевой ставки ЦБ РФ (1992–2026), пересчитанных в 411 помесячных значений (forward fill). Первые 200.

X_3: 822 цены закрытия SBER. Берётся дробная часть: (цена $\times$ 100) mod 100. При высокой ликвидности копейки — микроструктурный шум, распределённый $\approx$ равномерно на $[0, 99]$.

X_4: 100 цен IMOEX до кризиса 2022 ($\approx$ 3500–4200) + 100 после ($\approx$ 2000–2500), перемешанных случайно.

2 Первичное описание выборки (п. 4.1)

2.1 Эмпирические функции распределения

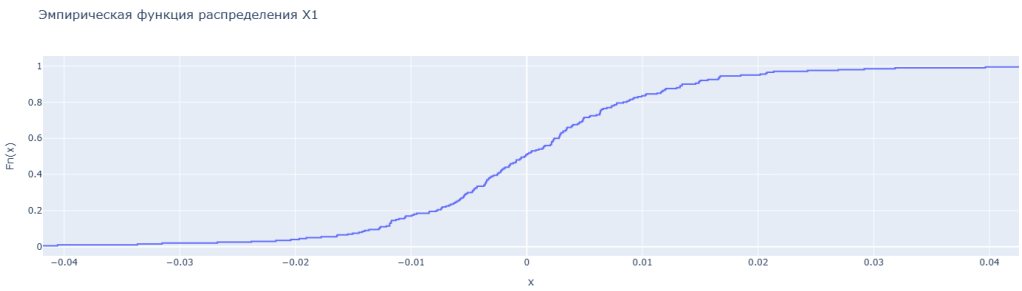

Рис. 1: ЭФР X_1: S-образная кривая (характерна для нормального распределения)

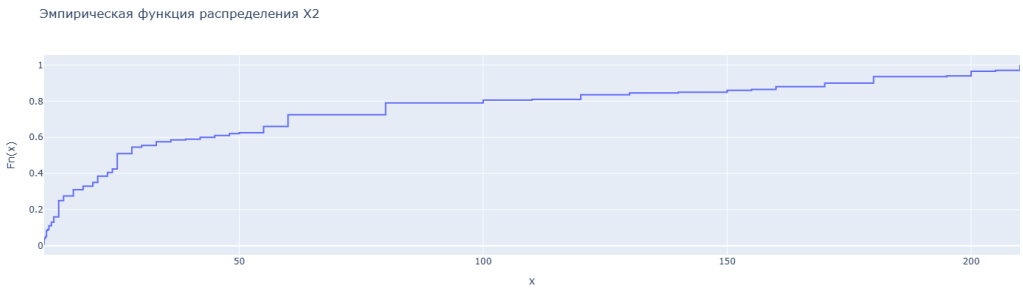

Рис. 2: ЭФР X_2: быстрый рост вначале, замедление — выпуклая форма (экспоненциальное)

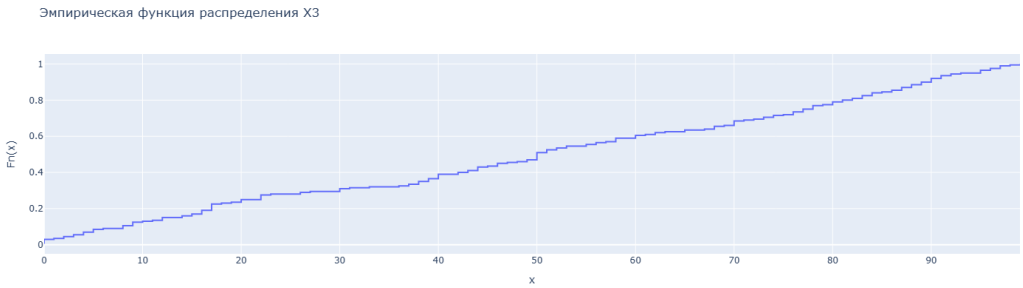

Рис. 3: ЭФР X_3: почти прямая линия (равномерное распределение)

2.2 Гистограммы

Для каждого столбца построены гистограммы по трём правилам: Стёрджес ($k = 1 + \lfloor \log_2 n \rfloor$), Скотт ($h = 3.5\hat{\sigma} n^{-1/3}$), Фридман-Диаконис ($h = 2 \cdot IQR \cdot n^{-1/3}$).

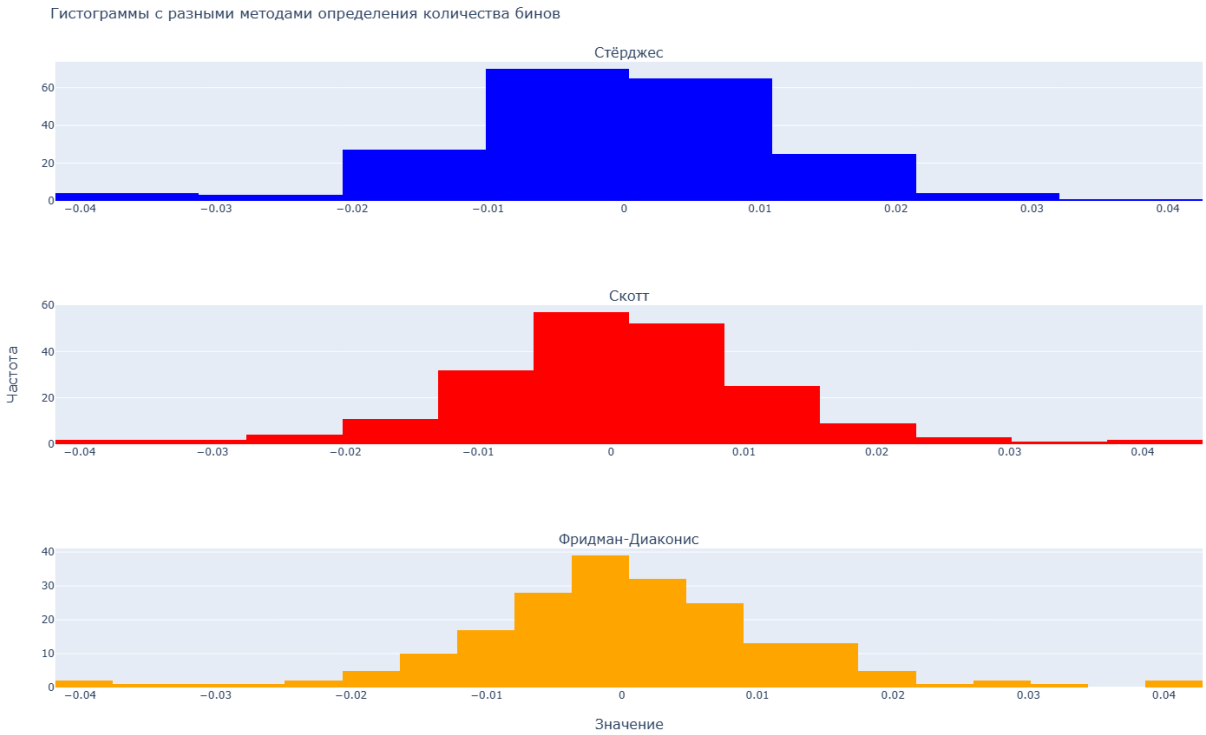

Рис. 4: Гистограммы X_1: колоколообразная форма

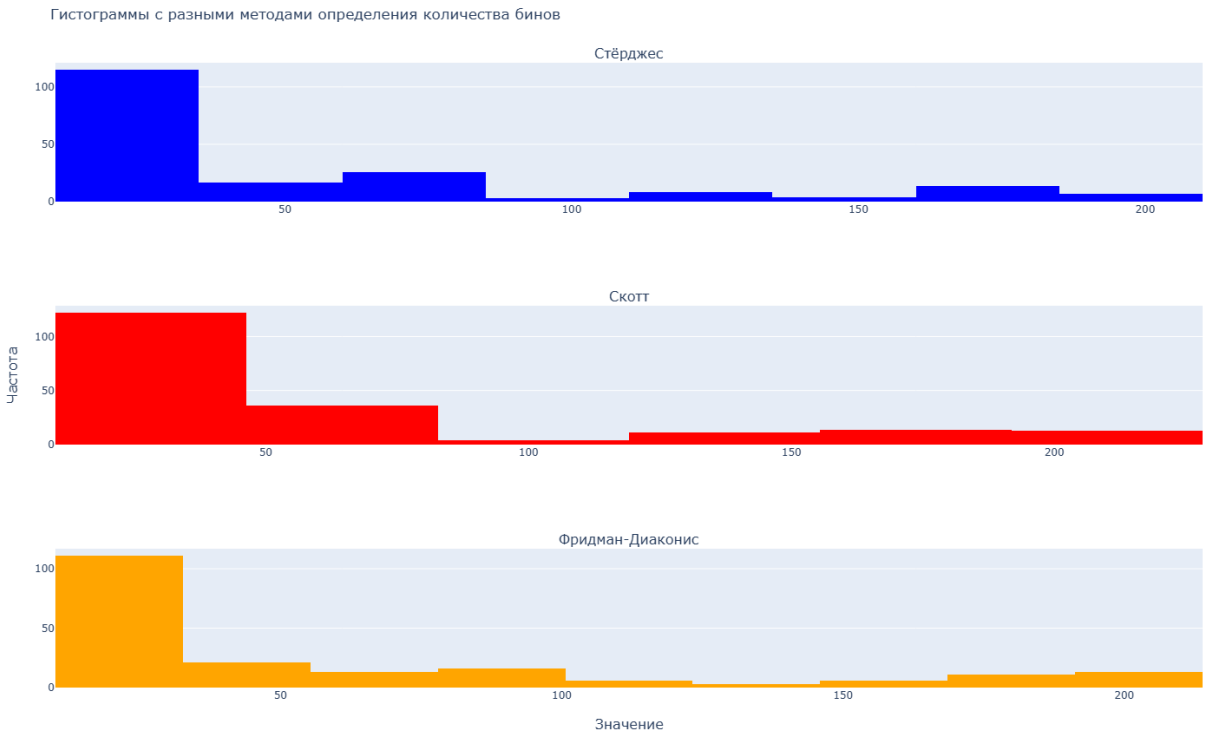

Рис. 5: Гистограммы X_2: правая асимметрия, длинный хвост

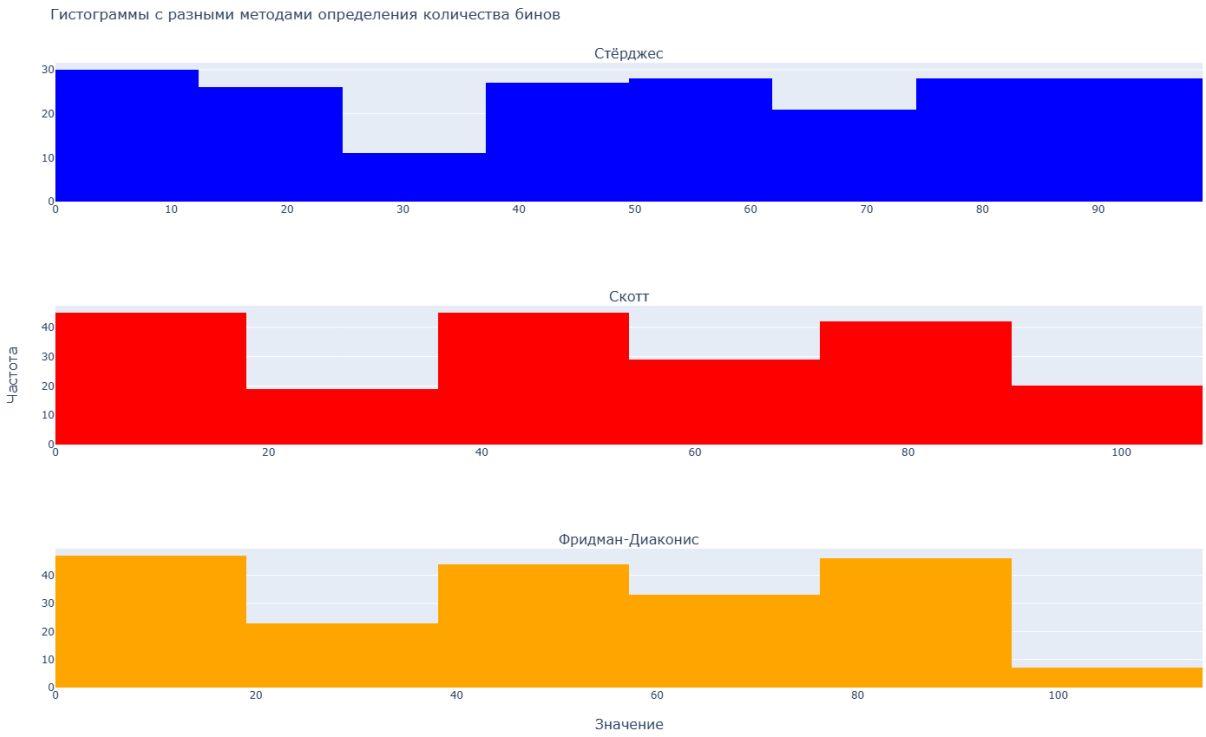

Рис. 6: Гистограммы X_3: плоская форма

2.3 Числовые характеристики

Таблица 2: Числовые характеристики выборки

Характеристика	X_1	X_2	X_3
$\bar{x}$	0.000071	58.22	50.02
S^2 (смещённая)	0.000144	3673.62	893.68
$\hat{\sigma}^2$ (несмещённая)	0.000145	3692.08	898.18
S	0.01199	60.61	29.89
$\hat{\sigma}$	0.01202	60.76	29.97
Медиана	-0.00014	25.0	50.0
Q_1	-0.006	13.75	21.5
Q_3	0.006	80.0	77.25

2.4 Описание формы

X_1: симметричное распределение (skew $= -0.01$), выбросы отсутствуют, естественных границ нет — лог-доходности теоретически от $-\infty$ до $+\infty$.

X_2: выраженная правая асимметрия (skew $= 1.34$), присутствуют выбросы в области высоких ставок (90-е годы), естественная нижняя граница (ставка ≥ 0).

X_3: симметричное (skew $= -0.10$), выбросы отсутствуют, естественные границы слева (0) и справа (99).

3 Предположение о виде закона распределения (п. 4.2)

X_1: колоколообразная гистограмма, S-образная ЭФР, медиана $\approx$ среднее, квартили симметричны $\Rightarrow$ **нормальное** $N(a, \sigma)$.

X_2: правая асимметрия, выпуклая ЭФР, медиана $\ll$ среднее, нижняя граница $\approx 10\%$ $\Rightarrow$ **экспоненциальное со сдвигом** $Exp(\lambda, c)$.

X_3: плоская гистограмма, линейная ЭФР, среднее = медиана = середина диапазона $\Rightarrow$ **равномерное** $U(a, b)$.

4 Оценивание параметров (п. 4.3)

4.1 X_1: нормальное $N(a, \sigma)$

Метод моментов: $EX = a$, $DX = \sigma^2 \Rightarrow \hat{a} = \bar{x} = 0.000071$, $\hat{\sigma} = S = 0.01199$.

ММП: $L(\mu, \sigma^2) = \prod_{i=1}^{n} \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x_i-\mu)^2}{2\sigma^2}\right)$

После дифференцирования $\ln L$: $\hat{\mu} = \bar{x}$, $\hat{\sigma}^2 = S^2$. Совпадает с ММ.

4.2 X_2: экспоненциальное со сдвигом $Exp(\lambda, c)$

Плотность: $f(x) = \lambda e^{-\lambda(x-c)}$, $x \geq c$. Теория: $EX = c + 1/\lambda$, $DX = 1/\lambda^2$.

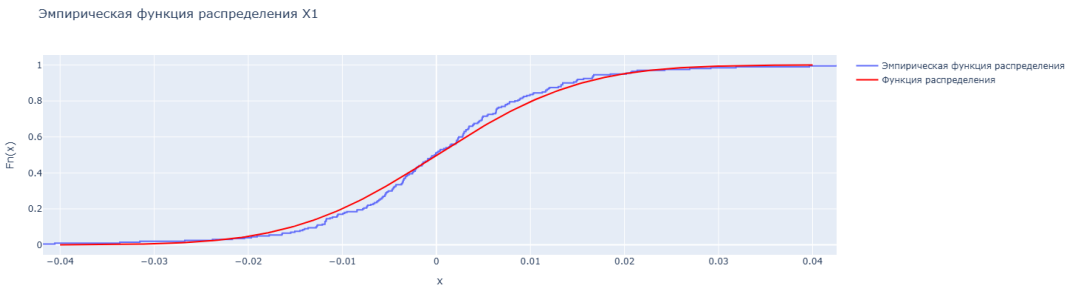

Рис. 7: X_2: сравнение ЭФР с теоретическими ФР, которые совпали

Метод моментов: $\hat{\lambda}_{MM} = 1/S$, $\hat{c}_{MM} = \bar{x} - 1/\hat{\lambda} = \bar{x} - S$.
ММП: $L(\lambda, c) = \lambda^n \exp\left(-\lambda \sum(x_i - c)\right)$ при $c \leq \min(x_i)$.
По c: $\partial \ln L/\partial c = n\lambda > 0$ — растёт, значит $\hat{c} = \min(x_i)$.
По λ: $\hat{\lambda} = 1/(\bar{x} - \hat{c})$.

Оценки различаются: ММ оценивает сдвиг через среднее и дисперсию, ММП — через минимум выборки.

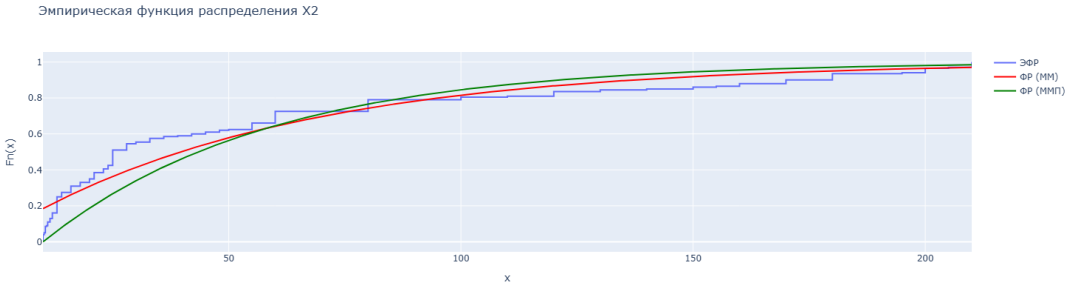

Рис. 8: X_2: сравнение ЭФР с теоретическими ФР (ММ и ММП)

4.3 X_3: равномерное $U(a, b)$

Метод моментов: $\hat{a} = \bar{x} - \sqrt{3}S = -1.89$, $\hat{b} = \bar{x} + \sqrt{3}S = 101.92$.

ММП: $L(a, b) = 1/(b - a)^n$ — максимизируется при минимальном $(b - a) \Rightarrow \hat{a} = \min(x_i) = 0$, $\hat{b} = \max(x_i) = 99$.

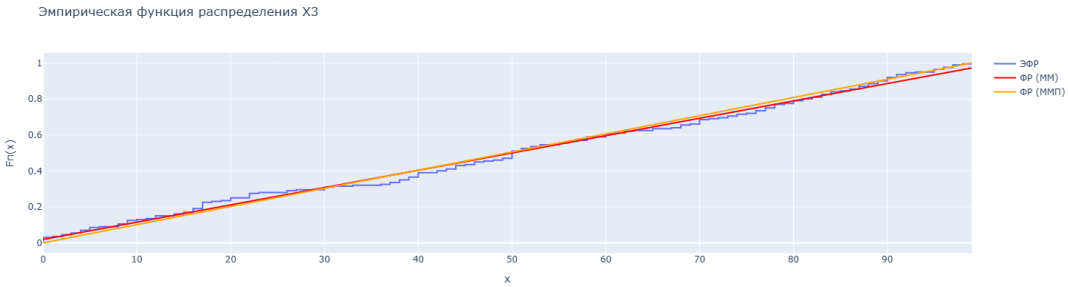

Рис. 9: X_3: сравнение ЭФР с теоретическими ФР (ММ и ММП)

5 Оценивание параметрической вероятности (п. 4.4)

Порог $x_0 = \bar{x} + \hat{\sigma}$. Оценка $P(X > x_0)$:

Таблица 3: Сравнение эмпирической и параметрической оценок $P(X > x_0)$

	x_0	Эмпирическая	Параметрическая	Расхождение
X_1	0.0121	0.1250	0.1587	0.0337
X_2	118.98	0.1900	0.1043	0.0857
X_3	79.98	0.2250	0.1921	0.0329

Расхождения умеренные: для X_1 и X_3 малы, для X_2 чуть больше из-за тяжёлого хвоста реальных данных.

6 Моменты по сгруппированной выборке (п. 4.5)

Формулы:

$$\hat{X}_g = \frac{1}{n}\sum_{k=1}^{m} n_k \hat{X}_k, \qquad \hat{\sigma}_g^2 = \frac{1}{n-1}\sum_{k=1}^{m} n_k (\hat{X}_k - \hat{X}_g)^2$$

Таблица 4: Сравнение оценок по исходным и сгруппированным данным

	$\hat{EX}$ (исходн.)	$\hat{EX}$ (групп.)	$\hat{DX}$ (исходн.)	$\hat{DX}$ (групп.)
X_1	0.000071	≈ 0.000071	0.000145	≈ 0.000145
X_2	58.22	≈ 58	3692.08	≈ 3700
X_3	50.02	≈ 50	898.18	≈ 900

Отклонения малы. Потеря точности связана с заменой значений серединами интервалов.

7 Доверительные интервалы (п. 4.6)

Уровень доверия $1 - \alpha = 0.95$.

7.1 Асимптотический ДИ для EX (по ЦПТ)

$$EX \in \left(\bar{x} - z_{1-\alpha/2}\frac{\hat{\sigma}}{\sqrt{n}},\ \bar{x} + z_{1-\alpha/2}\frac{\hat{\sigma}}{\sqrt{n}}\right)$$

Таблица 5: Асимптотические доверительные интервалы для EX

	Нижняя граница	Верхняя граница	Ширина
X_1	-0.001595	0.001737	0.003332
X_2	49.80	66.64	16.84
X_3	45.86	54.17	8.31

7.2 Точные ДИ для X_1 (нормальное распределение)

Для μ при неизвестной σ^2 (t-распределение):

$$\mu \in \left(\bar{x} \pm t_{1-\alpha/2,n-1}\frac{\hat{\sigma}}{\sqrt{n}}\right) = (-0.001605;\ 0.001747)$$

Для σ^2 (χ^2-распределение):

$$\sigma^2 \in \left(\frac{(n-1)\hat{\sigma}^2}{\chi^2_{1-\alpha/2}},\ \frac{(n-1)\hat{\sigma}^2}{\chi^2_{\alpha/2}}\right) = (0.00011985;\ 0.00017771)$$

7.3 Интерпретация

Доверительный интервал 95% означает: если повторить эксперимент многократно, то в 95% случаев построенный интервал накроет истинное значение параметра. Это **не** вероятность того, что параметр лежит в данном конкретном интервале — параметр фиксирован, а интервал случаен.

Асимптотический и точный ДИ для X_1 практически совпадают — при $n = 200$ квантили t-распределения уже очень близки к квантилям стандартного нормального.

8 Итоговый вывод (п. 4.7)

X_1 (лог-доходности IMOEX) — нормальное распределение $N(\hat{\mu}, \hat{\sigma})$. Гистограмма колоколообразная, ЭФР S-образная, асимметрия ≈ 0. Оценки ММ и ММП совпали.

X_2 (ставка рефинансирования ЦБ РФ) — экспоненциальное со сдвигом $Exp(\hat{\lambda}, \hat{c})$. Выраженная правая асимметрия, нижняя граница $\approx 10\%$. Оценки ММ и ММП различаются по параметру сдвига.

X_3 (копейки цены SBER) — равномерное распределение $U(0, 99)$. Плоская гистограмма, линейная ЭФР. ММП даёт более точные границы ($[0, 99]$), чем ММ ($[-1.89, 101.92]$).

Доверительные интервалы при $n = 200$ достаточно узкие. Эмпирические и параметрические оценки $P(X > x_0)$ расходятся незначительно, что подтверждает корректность выбранных моделей.

9 Бонус: бимодальность и кластеризация X_4

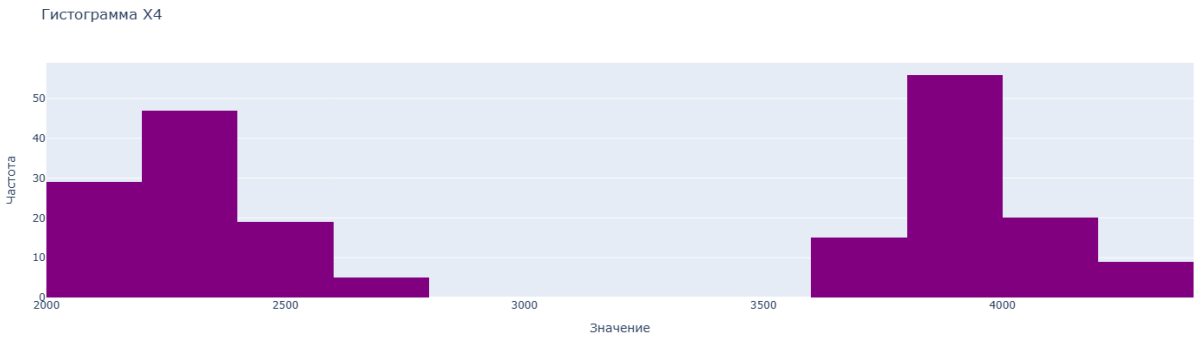

Рис. 10: X_4: гистограмма — два выраженных пика

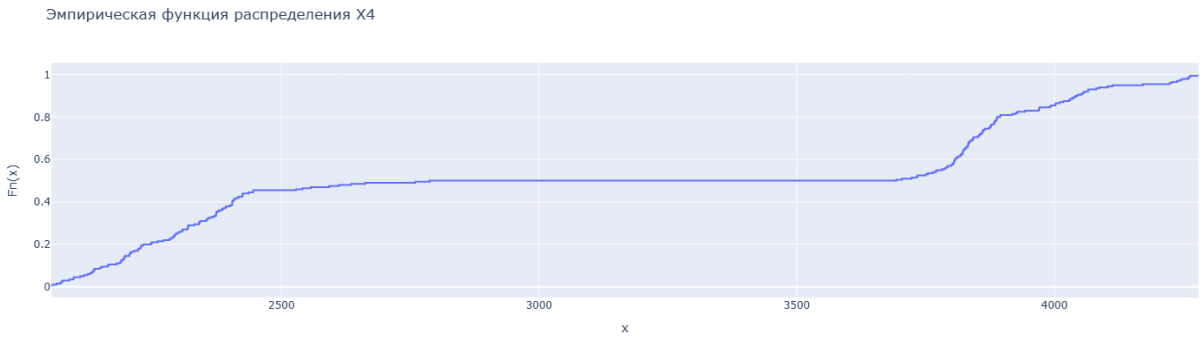

Рис. 11: X_4: ЭФР — два выраженных пика

Гистограмма X_4 имеет два пика: $\approx$ 2000–2500 (после кризиса) и $\approx$ 3500–4200 (до кризиса). ЭФР имеет «ступеньку» посередине.

Кластеризация k-средних ($k = 2$):

Таблица 6: Характеристики кластеров X_4

	n	Среднее	Стд. откл.
Кластер 0 (после кризиса)	100	2300.2	152.7
Кластер 1 (до кризиса)	100	3920.8	145.9
Общее	200	3110.5	—

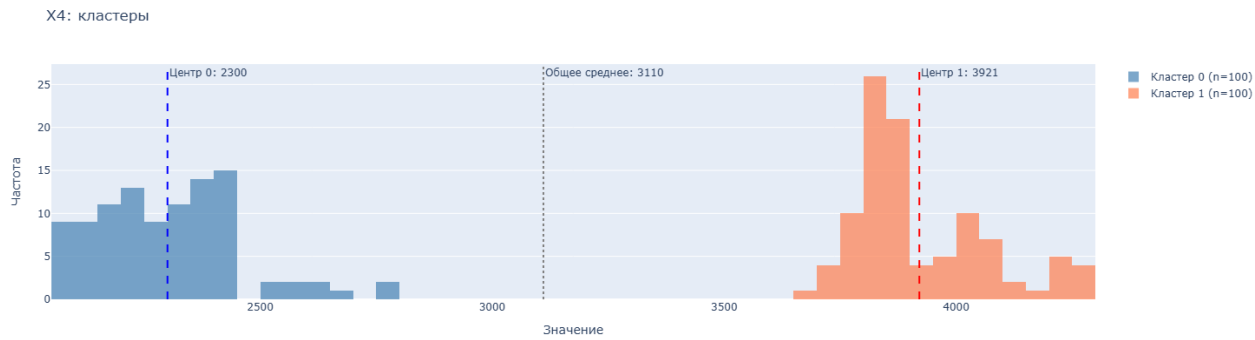

Рис. 12: X_4: гистограммы кластеров

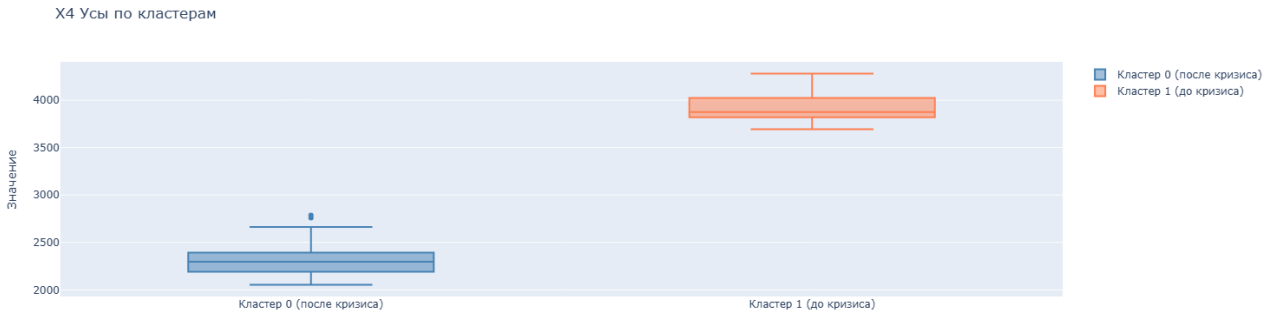

Рис. 13: X_4: боксы-усы

Общее среднее $\bar{x} = 3110$ не соответствует ни одному из режимов — оно оказывается между двумя модами. Это «средняя температура по больнице». Каждый кластер по отдельности хорошо описывается нормальным распределением.